PROYECTO INTEGRADOR M4

Reporte de Modelos

Predicción de fuga de clientes y segmentación estratégica para FinanceGuard

Curso: Data Science - Módulo 4

Estudiante: Joaquín Domingo

Rol: Integrador Analítico

Fecha: 13/07/2026

Contenido

1. Resumen ejecutivo
2. Contexto, objetivo y alcance
3. Enfoque metodológico integrado
4. Avance 1: Regresión Logística
5. Avance 2: modelos avanzados y selección de CatBoost
6. Avance 3: aprendizaje no supervisado
7. Integración de los enfoques supervisado y no supervisado
8. Recomendaciones estratégicas para FinanceGuard
9. Lecciones aprendidas y trade-offs
10. Limitaciones y próximos pasos
11. Conclusiones

1. Resumen ejecutivo

FinanceGuard enfrenta una tasa de abandono cercana al 20%, situación que genera pérdidas económicas y exige una estrategia de retención más precisa. A lo largo del proyecto se combinaron técnicas de aprendizaje supervisado, orientadas a estimar la probabilidad individual de churn, y métodos de aprendizaje no supervisado, destinados a comprender la estructura de la cartera e identificar perfiles de clientes con características diferenciadas.

El primer avance estableció una Regresión Logística como modelo baseline. Su principal fortaleza fue la interpretabilidad, ya que permitió analizar coeficientes, odds ratios e intervalos de confianza. Sin embargo, el modelo alcanzó un Recall de 0,19 y detectó solo 76 de los 407 abandonos presentes en el conjunto de prueba. Esta baja sensibilidad limitó su utilidad como mecanismo principal de priorización, aunque resultó valioso como referencia transparente para comparar modelos posteriores.

En el segundo avance se evaluaron Random Forest, XGBoost, LightGBM, CatBoost, una versión optimizada de XGBoost y un ensamble Stacking. CatBoost fue seleccionado como mejor modelo por presentar el equilibrio más favorable entre rendimiento y complejidad operativa. En prueba obtuvo Accuracy de 0,88, Precision de 0,82, Recall de 0,50, F1-Score de 0,62, ROC-AUC de 0,87 y PR-AUC de 0,73. Frente al baseline, identificó 129 abandonos adicionales, redujo los falsos negativos de 331 a 202 y disminuyó los falsos positivos de 53 a 44.

El tercer avance aportó una perspectiva complementaria mediante K-Means, DBSCAN, PCA y t-SNE. K-Means permitió identificar cuatro perfiles operativos. El Cluster 3, denominado “Senior con mayor actividad”, presentó la mayor tasa de churn, con 44,37%, por lo que requiere una intervención intensiva. El Cluster 2, “Saldo alto y producto único”, concentró 738 abandonos y el 36,23% del churn total, lo que lo convierte en una prioridad por volumen. DBSCAN identificó además 700 observaciones de menor densidad cuya tasa de churn fue de 56,14%, hallazgo que sugiere la necesidad de analizar perfiles atípicos sin confundirlos con predicciones individuales.

La recomendación final es utilizar CatBoost como motor de priorización y K-Means como capa de contexto para personalizar las acciones. El score individual debe indicar a quién contactar, mientras que el segmento debe orientar el tipo de intervención. La implementación debería comenzar con un piloto controlado que mida retención incremental, costo de contacto y valor económico generado.

2. Contexto, objetivo y alcance

FinanceGuard es un banco digital en crecimiento que cuenta con 10.000 clientes en el dataset analizado. La organización detectó una tasa anual de abandono cercana al 20% y definió como objetivo de negocio reducirla al 15%. En este contexto, el propósito del proyecto fue construir una visión analítica integral que permitiera anticipar el churn, comprender los perfiles de clientes y traducir los resultados técnicos en recomendaciones accionables para el equipo de retención.

El alcance incluyó tres etapas. La primera se concentró en el análisis exploratorio, la preparación de datos y la construcción de un modelo baseline interpretable. La segunda amplió el análisis mediante algoritmos de árboles, gradient boosting, optimización de hiperparámetros y Stacking. La tercera

exploró la estructura de la cartera mediante clustering y reducción de dimensionalidad. Este cuarto avance consolida los resultados, analiza los trade-offs y propone una estrategia integrada.

El dataset contiene variables demográficas, financieras y de relación con el banco, entre ellas edad, geografía, género, antigüedad, saldo, cantidad de productos, tenencia de tarjeta, actividad y salario estimado. La variable objetivo es Exited, donde el valor 1 representa a un cliente que abandonó el banco y el valor 0 a un cliente que permaneció activo.

3. Enfoque

La evaluación supervisada mantuvo un protocolo consistente. Se utilizó una división estratificada entre entrenamiento y prueba para preservar la proporción de la clase minoritaria, y se aplicó validación cruzada mediante StratifiedKFold en la comparación de modelos. Dado el desbalance del problema, la Accuracy se interpretó junto con Precision, Recall, F1-Score, ROC-AUC y PR-AUC. La PR-AUC recibió especial atención porque resume el equilibrio entre precisión y sensibilidad sobre la clase positiva, que es la de mayor interés operativo.

El conjunto de prueba se preservó para la evaluación final y no se utilizó para ajustar decisiones de entrenamiento. Esto permitió comparar los modelos bajo condiciones homogéneas. Asimismo, las conclusiones no se basaron exclusivamente en una métrica: se consideraron el rendimiento, la estabilidad observada en validación cruzada, la interpretabilidad, la complejidad operativa y la utilidad para el negocio.

En el análisis no supervisado, Exited fue excluida de la matriz utilizada para formar los clusters. Las tasas de churn se calcularon únicamente después de obtener los grupos, con el propósito de describirlos y no de influir en su construcción. Del mismo modo, las variables derivadas no incorporaron tasas de churn, rankings de riesgo ni prioridades comerciales, lo que evitó fuga de información.

La combinación de ambos enfoques se concibe como una arquitectura de decisión. Los modelos supervisados generan un score de riesgo individual; el clustering aporta contexto para comprender el perfil del cliente y adaptar la estrategia de contacto. Ningún cluster se interpreta como una causa de churn ni como una predicción por sí mismo.

4. Avance 1: Regresión Logística

4.1 Desempeño del modelo baseline

La Regresión Logística funcionó como referencia inicial para evaluar el problema de clasificación. En el conjunto de prueba obtuvo una Accuracy de 0,81, una Precision de 0,59, un Recall de 0,19, un F1-Score de 0,28, un ROC-AUC de 0,77 y una PR-AUC de 0,48. Aunque la Accuracy puede parecer aceptable, el resultado debe analizarse considerando que aproximadamente el 80% de los clientes pertenece a la clase que permanece activa.

Métrica	Resultado
Accuracy	0.81
Precision	0.59
Recall	0.19
F1-Score	0.28
ROC-AUC	0.77
PR-AUC	0.48

Tabla 1. Métricas del modelo baseline sobre el conjunto de prueba.

La principal debilidad se observó en el Recall. El modelo identificó 76 de los 407 clientes que efectivamente abandonaron y dejó 331 casos como falsos negativos. Desde la perspectiva del negocio, estos falsos negativos representan clientes que no habrían sido priorizados por una campaña de retención pese a encontrarse en riesgo real. Por esta razón, el baseline resultó insuficiente como motor principal de intervención.

4.2 Interpretabilidad y coeficientes relevantes

La principal contribución de la Regresión Logística fue su capacidad explicativa. Los coeficientes permiten conocer la dirección de la asociación entre cada variable y los log-odds de churn, mientras que los odds ratios facilitan una interpretación multiplicativa. Entre las variables más relevantes se encontraron la actividad del cliente, la geografía, la edad, el género y el saldo.

Variable	Coeficiente	Odds ratio	Interpretación
IsActiveMember	-1,03	0,36	Asociación con menores odds de churn.
Geography_Germany	0,82	2,27	Mayores odds respecto de la categoría de referencia.

Variable	Coeficiente	Odds ratio	Interpretación
Age	0,74	2,09	Mayor edad estandarizada, mayores odds.
Gender_Male	-0,52	0,59	Menores odds respecto de la categoría de referencia.
Balance	0,16	1,17	Asociación positiva moderada.

Tabla 2. Coeficientes y odds ratios seleccionados de la Regresión Logística.

Las variables numéricas fueron estandarizadas, por lo que sus odds ratios representan el cambio asociado a un aumento de una desviación estándar. Estas asociaciones no deben interpretarse como relaciones causales. El modelo describe patrones presentes en los datos, pero no demuestra que modificar una variable produzca necesariamente un cambio en la probabilidad de abandono.

4.3 Fortalezas, limitaciones y rol recomendado

La Regresión Logística ofrece alta interpretabilidad, entrenamiento rápido y baja complejidad operativa. Permite comunicar la dirección de las asociaciones y constituye una herramienta útil para validar el flujo completo de preparación, entrenamiento y evaluación. También sirve como benchmark estable frente al cual medir la ganancia de modelos más complejos.

Su principal limitación es la menor capacidad para representar relaciones no lineales e interacciones complejas. En este caso, esa limitación se tradujo en un Recall muy bajo y en un F1-Score reducido. El trade-off central fue interpretabilidad versus capacidad predictiva: el modelo explica mejor, pero detecta menos abandonos. Por ello, el rol recomendado es el de benchmark, herramienta de control y complemento interpretativo, no el de mecanismo exclusivo de priorización.

5. Avance 2: modelos avanzados y selección de CatBoost

5.1 Comparación de modelos

En el segundo avance se evaluaron Random Forest, XGBoost, LightGBM, CatBoost, una versión optimizada de XGBoost mediante Grid Search y un ensamble Stacking. Todos los modelos basados en árboles superaron ampliamente al baseline en las métricas orientadas a la clase churn. La comparación se realizó bajo un protocolo común, lo que permitió atribuir las diferencias al comportamiento de los algoritmos y no a cambios en la partición de datos.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
Regresión Logística	0,81	0,59	0,19	0,28	0,77	0,48
Random Forest	0,87	0,82	0,44	0,58	0,86	0,71
XGBoost inicial	0,87	0,78	0,49	0,60	0,87	0,72
LightGBM	0,86	0,74	0,49	0,59	0,86	0,70
CatBoost	0,88	0,82	0,50	0,62	0,87	0,73
XGBoost optimizado	0,87	0,79	0,50	0,61	0,87	0,72
Stacking	0,87	0,79	0,50	0,61	0,87	0,73

Tabla 3. Comparación de modelos supervisados sobre el conjunto de prueba.

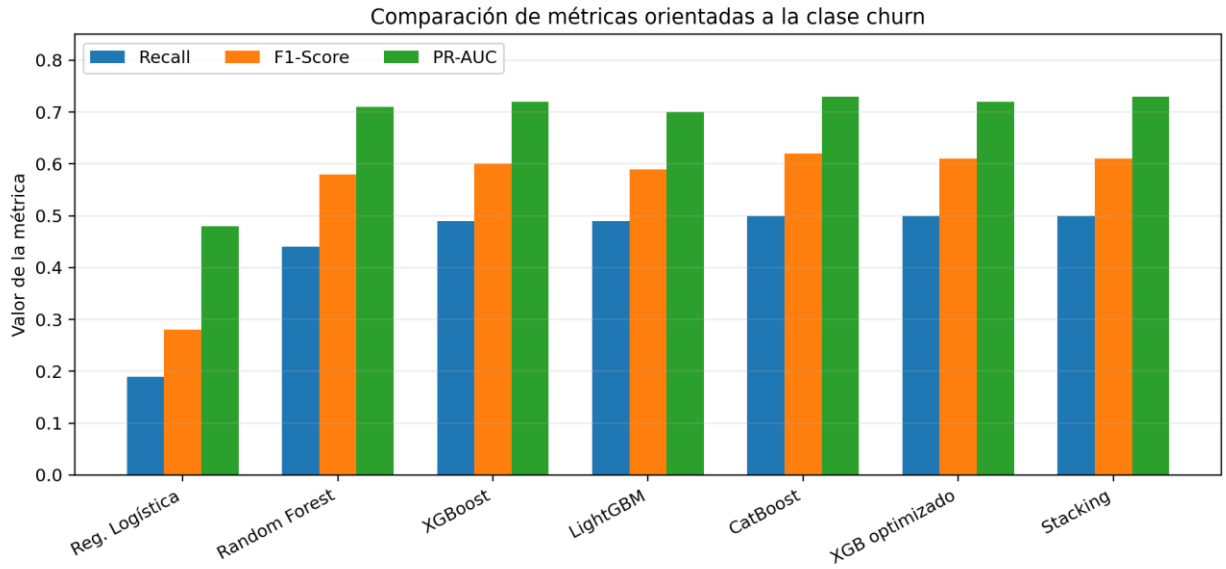


Figura 1. Comparación de Recall, F1-Score y PR-AUC para los modelos evaluados.

CatBoost obtuvo la mayor Accuracy, mantuvo una Precision elevada, alcanzó el mayor F1-Score y compartió la mayor PR-AUC con Stacking. La diferencia frente al ensamble fue principalmente

operativa: Stacking no produjo una mejora clara en Recall, F1-Score o ROC-AUC, pero requería mantener varios modelos base y un meta-modelo. La ganancia marginal no justificó esa complejidad adicional.

5.2 Ganancia frente al baseline

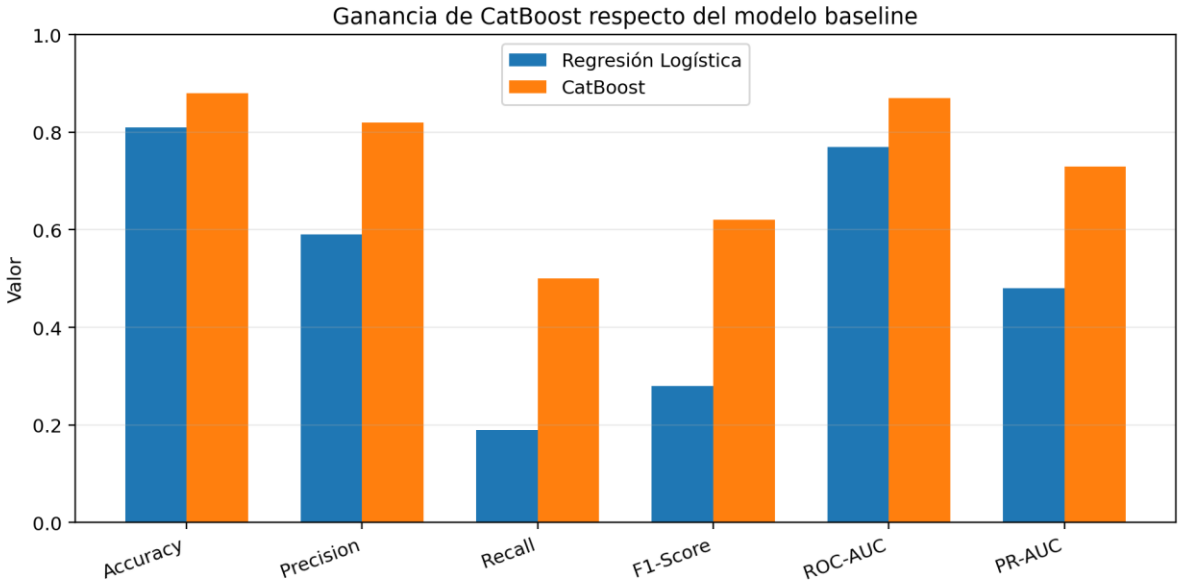


Figura 2. Comparación de métricas entre Regresión Logística y CatBoost.

La mejora de CatBoost fue relevante tanto desde la perspectiva técnica como desde la perspectiva del negocio. Los verdaderos positivos aumentaron de 76 a 205, lo que implica 129 abandonos adicionales correctamente identificados. En paralelo, los falsos negativos disminuyeron de 331 a 202. La mejora en sensibilidad no se obtuvo a costa de generar una gran cantidad de alertas erróneas: los falsos positivos se redujeron de 53 a 44 y los verdaderos negativos aumentaron de 1.540 a 1.549.

Este patrón es especialmente valioso para una campaña de retención. El modelo no solo amplía la cobertura sobre los clientes que abandonan, sino que también mejora la precisión de la selección. Aun así, un Recall de 0,50 significa que aproximadamente la mitad de los abandonos continúa sin ser detectada con el threshold utilizado, por lo que existe margen para optimizar el punto de corte en una etapa posterior considerando costos y beneficios de negocio.

5.3 Importancia de variables y capacidad explicativa

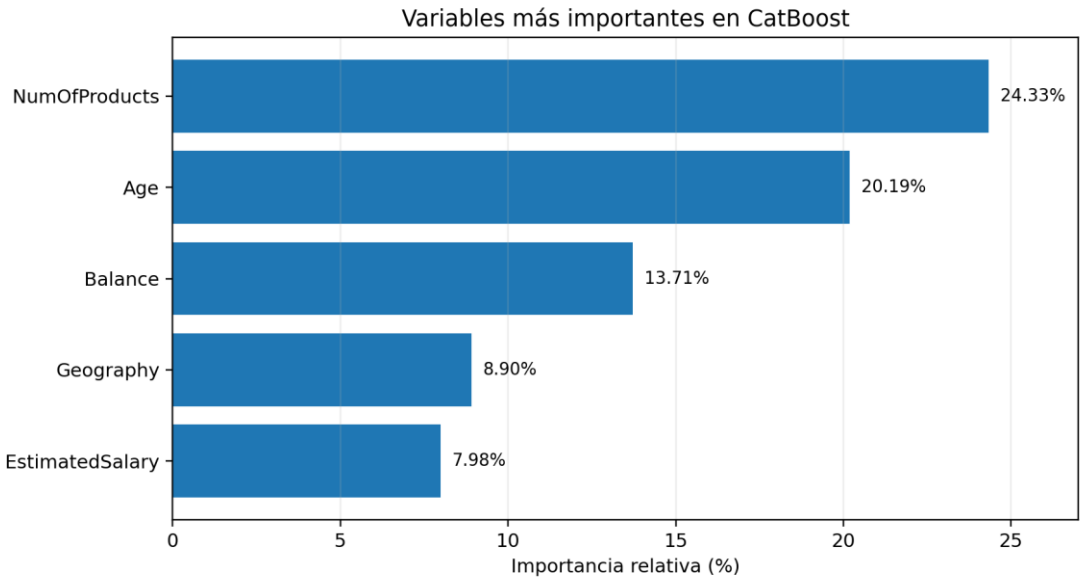


Figura 3. Cinco variables con mayor importancia relativa en CatBoost.

Las variables más importantes fueron NumOfProducts, con 24,33%; Age, con 20,19%; Balance, con 13,71%; Geography, con 8,90%; y EstimatedSalary, con 7,98%. En conjunto, estas cinco variables concentraron aproximadamente el 75% de la importancia total. El modelo utiliza, por lo tanto, información relacionada con la profundidad de la relación bancaria, la edad, el nivel de saldo, la ubicación geográfica y la situación económica estimada.

La importancia de variables no debe confundirse con la dirección del efecto ni con causalidad. Una variable puede ser muy útil para dividir observaciones y mejorar la predicción sin indicar si valores altos aumentan o disminuyen el churn. En este punto, la Regresión Logística conserva valor como complemento interpretativo, porque permite observar la dirección de ciertas asociaciones.

5.4 Fortalezas, limitaciones y trade-offs

CatBoost presenta un equilibrio favorable entre desempeño y viabilidad operativa. Captura relaciones no lineales e interacciones que la Regresión Logística no representa con la misma flexibilidad, mantiene una Precision alta y ofrece un ranking de riesgo individual. Además, su implementación es menos compleja que la de un ensamble multinivel y su rendimiento fue estable en la comparación realizada.

Entre sus limitaciones se encuentran la menor interpretabilidad directa, la dificultad para inferir la dirección de los efectos a partir de la importancia y la persistencia de un número relevante de falsos negativos. La evaluación también se realizó sobre un único dataset sin dimensión temporal, información transaccional detallada ni variables de valor económico. En consecuencia, el modelo debe considerarse una solución predictiva sólida dentro del alcance disponible, pero no una representación completa del comportamiento futuro de la cartera.

6. Avance 3: aprendizaje no supervisado

6.1 Selección de K-Means como método principal

K-Means fue seleccionado como método principal de segmentación porque permitió asignar al 100% de los clientes a grupos operativos y facilitó una interpretación clara de los centroides. Se evaluaron valores de K entre 2 y 10 y se eligió K=4 considerando el método del codo, el coeficiente de silueta, la interpretabilidad y la utilidad para el negocio. La inercia fue de 56.180,40 y el coeficiente de silueta de 0,1299.

El valor de silueta indica que los grupos presentan superposición y que no constituyen categorías completamente separadas. Sin embargo, la segmentación resultó útil para describir perfiles con diferencias relevantes en edad, saldo, cantidad de productos y tasa de churn. La decisión de utilizar cuatro clusters respondió, por lo tanto, a un equilibrio entre calidad geométrica e interpretabilidad operacional.

6.2 Perfiles identificados

Segmento	Clientes	Edad prom.	Saldo prom.	Productos	Churn	Prioridad
C0 - Saldo alto y multiproducto	1.978	36,88	121.746,10	2,13	20,02%	Intermedia
C1 - Saldo bajo y multiproducto	3.269	35,69	1.002,20	1,82	10,61%	Baja
C2 - Saldo alto y producto único	3.500	35,90	120.929,25	1,00	21,09%	Alta por volumen
C3 - Senior con mayor actividad	1.253	59,02	77.826,47	1,30	44,37%	Crítica por tasa

Tabla 4. Perfil resumido de los cuatro segmentos K-Means.

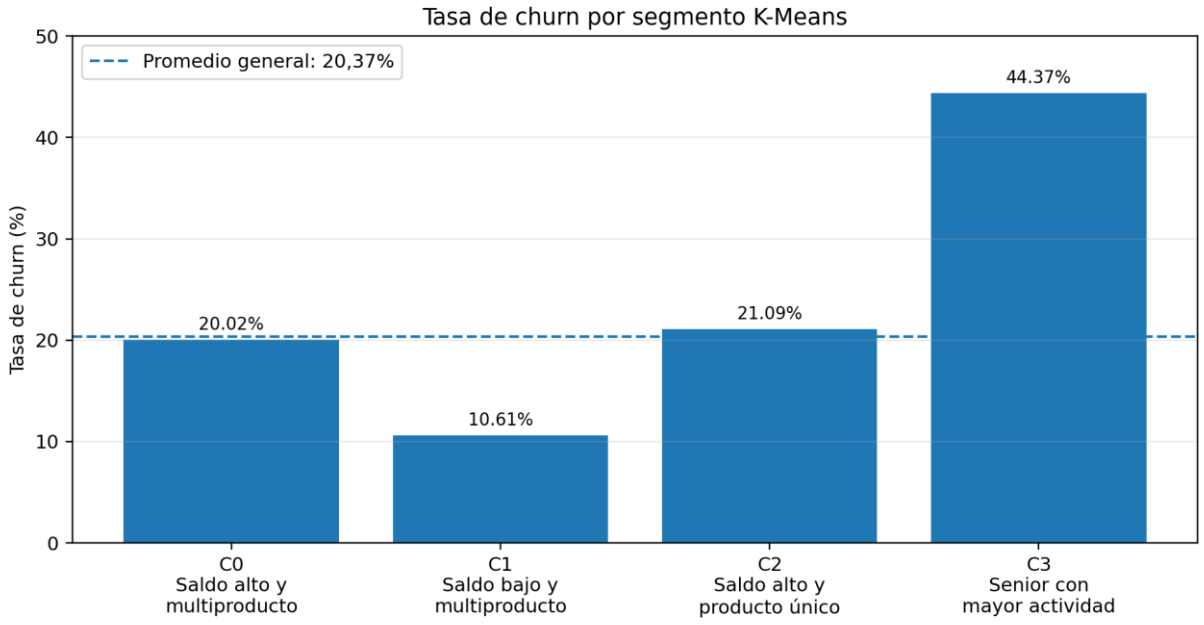


Figura 4. Tasa de churn por cluster frente al promedio general.

El Cluster 0 reúne clientes con saldo alto y múltiples productos. Su tasa de churn, 20,02%, es similar al promedio general. Se trata de un grupo de prioridad intermedia para el cual las acciones deberían enfocarse en fidelización, beneficios relevantes y prevención del deterioro de la relación.

El Cluster 1 concentra clientes con saldo muy bajo y más de un producto. Presenta la menor tasa de churn, 10,61%, y representa el 32,69% de la base. Su prioridad es baja; por ello, resultan más apropiadas las comunicaciones digitales de bajo costo, el estímulo del uso efectivo de los productos y el análisis de rentabilidad antes de asignar incentivos intensivos.

El Cluster 2 incluye clientes con saldo alto y un único producto. Aunque su tasa de churn, 21,09%, es cercana al promedio, concentra 3.500 clientes y 738 abandonos, equivalentes al 36,23% del churn total. Esta combinación convierte al segmento en una prioridad alta por volumen. Las acciones deberían ser escalables y orientarse a profundizar la relación mediante propuestas relevantes, sin asumir que la incorporación de más productos causará necesariamente una reducción del churn.

El Cluster 3 está conformado por clientes de mayor edad, con un promedio de 59,02 años, y presenta una tasa de churn de 44,37%. Aunque representa solo el 12,53% de la base, concentra 556 abandonos y el 27,30% del churn total. La intensidad del fenómeno justifica una prioridad crítica, con contacto proactivo, soporte personalizado e investigación de posibles fricciones de servicio.

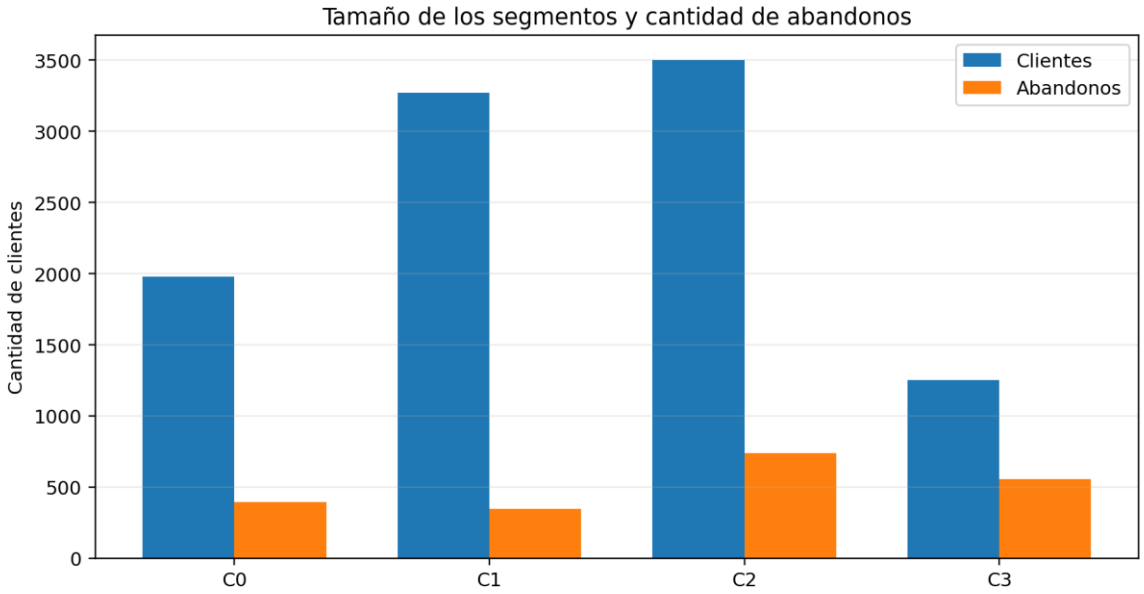


Figura 5. Tamaño de los segmentos y cantidad absoluta de abandonos.

La comparación entre tasa y volumen muestra que la priorización no debe basarse en un único indicador. El Cluster 3 requiere intensidad por su elevada tasa, mientras que el Cluster 2 requiere escala porque concentra la mayor cantidad absoluta de bajas. Este hallazgo es central para asignar recursos de manera eficiente.

6.3 Aporte complementario de DBSCAN

DBSCAN se utilizó como técnica complementaria para analizar densidad y detectar perfiles menos frecuentes. Con eps igual a 1,698 y min_samples igual a 26, identificó dos clusters, asignó 9.300 clientes y clasificó 700 observaciones como ruido, equivalentes al 7% de la base. El coeficiente de silueta fue de 0,1283, valor similar al obtenido por K-Means.

Las observaciones clasificadas como ruido presentaron una tasa de churn de 56,14% y concentraron 393 abandonos. Este resultado no significa que el ruido sea una predicción ni que esas observaciones sean errores. Indica que se ubican en regiones de menor densidad bajo la configuración seleccionada y que podrían representar perfiles heterogéneos que merecen análisis adicional. Debido a que DBSCAN no ofrece un método estándar de predicción para nuevos casos, se mantuvo como herramienta exploratoria y no como segmentación operativa principal.

6.4 PCA, t-SNE y variables derivadas

PCA permitió resumir la información y estudiar la estructura global. Seis componentes conservaron el 80,21% de la varianza y ocho componentes alcanzaron el 91,33%. Las primeras tres explicaron el 44,26%, por lo que las visualizaciones en dos o tres dimensiones deben interpretarse como proyecciones parciales y no como una representación completa del espacio original. La primera componente estuvo asociada principalmente con saldo y cantidad de productos; la segunda con salario estimado, antigüedad y edad; y la tercera con puntaje crediticio.

t-SNE se utilizó en dos dimensiones con perplexity igual a 30 para explorar relaciones locales y patrones no lineales. La técnica permitió observar mayor dispersión en algunos perfiles, especialmente en el Cluster 3, pero sus coordenadas se interpretaron únicamente con fines visuales. No se utilizaron como evidencia de separación definitiva ni como base directa para decisiones de negocio.

El feature engineering generó 17 variables derivadas y llevó el dataset enriquecido a 31 columnas. Entre las variables potencialmente reutilizables se encuentran el cluster y perfil K-Means, la distancia al centroide asignado, las distancias a cada centroide, el segundo cluster más cercano, el margen de separación y las primeras componentes principales. También se conservaron variables exploratorias relacionadas con DBSCAN y t-SNE. Cualquier incorporación futura de estas features al modelo supervisado deberá evaluarse con el mismo protocolo de validación, sin asumir una mejora automática.

7. Integración de los enfoques supervisado y no supervisado

Los enfoques supervisado y no supervisado responden preguntas diferentes. CatBoost estima qué probabilidad tiene un cliente individual de abandonar y permite ordenar la cartera según riesgo. K-Means describe a qué perfil pertenece el cliente y qué tipo de estrategia podría resultar más adecuada. La integración de ambas perspectivas permite pasar de campañas masivas a intervenciones focalizadas y diferenciadas.

El principio operativo recomendado es que la probabilidad individual lidere la priorización. Un cliente con score alto debería recibir mayor atención, independientemente de su cluster. El segmento aporta una segunda capa de contexto para definir el canal, el mensaje, la intensidad del contacto y la propuesta de valor. De esta forma, el clustering no reemplaza el modelo predictivo, sino que mejora la personalización de las acciones.

Para clientes de riesgo alto pertenecientes al Cluster 3, la estrategia debería combinar contacto prioritario, asistencia personalizada y diagnóstico de fricciones. Para los clientes de riesgo alto del Cluster 2, conviene diseñar intervenciones escalables orientadas a profundizar la relación. En el Cluster 0, los casos de riesgo medio pueden recibir acciones de fidelización y prevención. En el Cluster 1, las comunicaciones digitales de bajo costo son más apropiadas cuando el riesgo es bajo o moderado.

Una decisión comercial completa debería incorporar además el valor económico del cliente, el costo de contacto, el costo del incentivo, la capacidad operativa y el historial reciente. El riesgo estadístico indica probabilidad de abandono, pero no determina por sí solo el retorno esperado de una intervención. El objetivo final debería ser maximizar retención incremental y valor generado, no solo identificar clientes con score elevado.

8. Recomendaciones estratégicas para FinanceGuard

1. Utilizar CatBoost como motor de priorización. El modelo debería generar un ranking de riesgo que permita ordenar a los clientes y asignar recursos de manera focalizada. La probabilidad estimada debe utilizarse como criterio principal para decidir a quién contactar, evitando campañas masivas no diferenciadas.

2. Implementar una estrategia intensiva para el Cluster 3. La tasa de churn de 44,37% justifica una intervención prioritaria. Se recomienda combinar contacto proactivo, soporte personalizado, revisión de dificultades de uso y análisis cualitativo de motivos de abandono. La estrategia debe considerar las necesidades específicas de una población de mayor edad.

3. Diseñar acciones escalables para el Cluster 2. Este segmento concentra el mayor volumen absoluto de bajas. Las iniciativas deben poder aplicarse a gran escala y evaluar propuestas que aumenten la profundidad de la relación, siempre mediante pruebas controladas que permitan distinguir asociación de efecto causal.

4. Mantener acciones eficientes en los Clusters 0 y 1. En el Cluster 0 conviene priorizar fidelización, beneficios relevantes y prevención de deterioro. En el Cluster 1, por su menor tasa de

churn, deberían prevalecer comunicaciones digitales de bajo costo, estímulo del uso y evaluación de rentabilidad.

5. Validar la estrategia mediante un piloto controlado. Se recomienda comparar un grupo intervenido con un grupo de control y medir retención incremental. Esta evaluación permitirá determinar si la acción genera una mejora real por encima del comportamiento esperado sin intervención.

6. Incorporar métricas económicas. El seguimiento debería incluir costo de contacto, costo del incentivo, margen, valor de vida del cliente y retorno de la campaña. La optimización de la retención debe orientarse a valor económico y no exclusivamente a métricas predictivas.

7. Monitorear el modelo y la cartera. Es necesario revisar periódicamente la distribución de scores, las métricas de clasificación, el desempeño por segmento y los resultados de negocio. También deben detectarse cambios en las características de los clientes que puedan deteriorar la generalización del modelo.

8. Incorporar nuevas fuentes de información. Las futuras versiones deberían sumar datos temporales y transaccionales, uso de canales, reclamos, satisfacción, contactos con atención, motivos de baja, rentabilidad y valor del cliente. Estas variables podrían capturar señales de comportamiento más cercanas al momento del abandono.

9. Lecciones aprendidas y trade-offs

9.1 Cuándo utilizar aprendizaje supervisado y no supervisado

El aprendizaje supervisado es apropiado cuando existe una variable objetivo histórica y el propósito es predecir un resultado conocido. En este proyecto, Exited permitió entrenar modelos para estimar la probabilidad de churn. La calidad del modelo pudo medirse objetivamente mediante métricas calculadas contra valores reales. Su principal fortaleza fue la priorización individual; su limitación fue la dependencia de etiquetas históricas y la menor interpretabilidad de los modelos más complejos.

El aprendizaje no supervisado resulta útil cuando el objetivo es descubrir estructuras, similitudes, densidades o patrones sin utilizar una etiqueta. K-Means y DBSCAN permitieron comprender la heterogeneidad de la cartera y diseñar perfiles de intervención. Sin embargo, los clusters no representan verdades únicas ni predicen churn por sí solos. Su utilidad depende de la estabilidad, la interpretabilidad y la capacidad de traducirlos en acciones concretas.

La principal lección es que ambos enfoques son complementarios. El aprendizaje supervisado responde “quién tiene mayor probabilidad de abandonar”, mientras que el no supervisado responde “qué perfiles existen y cómo se diferencian”. Utilizados en conjunto, permiten priorizar y personalizar.

9.2 Trade-offs entre los modelos

Enfoque	Rendimiento	Interpretabilidad	Complejidad operativa	Uso recomendado
Regresión Logística	Moderado-bajo	Alta	Baja	Benchmark, explicación y control.
Random Forest	Alto	Media	Media	Alternativa robusta con buena Precision.
XGBoost / LightGBM	Alto	Media-baja	Media-alta	Modelos competitivos cuando optimización o velocidad son prioritarias.
CatBoost	Muy alto	Media-baja	Media	Modelo principal para priorización de riesgo.
Stacking	Muy alto	Baja	Alta	Adecuado solo si demuestra una ganancia clara y estable.

Tabla 5. Síntesis de trade-offs entre los principales enfoques supervisados.

El mejor modelo no es necesariamente el más complejo. La selección debe equilibrar capacidad predictiva, estabilidad, interpretabilidad suficiente, costo de mantenimiento y utilidad para la decisión. CatBoost fue elegido porque mejoró el rendimiento frente al baseline y ofreció una complejidad menor que Stacking sin sacrificar métricas relevantes.

9.3 Consideraciones para futuros proyectos de churn

Los proyectos futuros deberían evitar utilizar Accuracy como única métrica en escenarios desbalanceados y definir una métrica principal coherente con el costo de los errores. También es fundamental preservar un conjunto de prueba independiente, utilizar validación cruzada, prevenir fuga de información durante el feature engineering y diferenciar importancia predictiva, asociación estadística y causalidad.

La complejidad operativa debe evaluarse junto con la ganancia de desempeño. Un modelo ligeramente superior puede no ser conveniente si exige una infraestructura mucho más costosa o difícil de mantener. Finalmente, el éxito debe medirse con resultados de negocio, como retención incremental y retorno económico, y no únicamente con métricas técnicas.

10. Limitaciones y próximos pasos

El análisis presenta limitaciones relacionadas con los datos disponibles. El dataset no incluye historial temporal, transacciones, uso detallado de canales, reclamos, satisfacción, motivos de abandono, rentabilidad, costo de atención ni valor de vida del cliente. Estas ausencias restringen la posibilidad de capturar cambios recientes de comportamiento y de optimizar la intervención desde una perspectiva económica.

En el plano metodológico, CatBoost continúa omitiendo aproximadamente la mitad de los abandonos bajo el threshold utilizado. La importancia de variables no muestra dirección ni causalidad. K-Means presenta superposición entre perfiles, DBSCAN es sensible a eps, min_samples y escalamiento, y las visualizaciones de PCA y t-SNE representan solo una parte de la estructura original. Además, la evaluación sobre un único dataset limita la validación externa.

Como próximos pasos se recomienda incorporar variables temporales y transaccionales, evaluar la estabilidad del modelo a lo largo del tiempo, estudiar calibración y threshold según costos de negocio, validar las features derivadas del clustering, medir el desempeño por subgrupos y diseñar experimentos controlados. La estrategia debe incluir monitoreo continuo y criterios de reentrenamiento cuando se detecten cambios significativos en la población o en la calidad predictiva.

Ninguna variable, cluster o score demuestra que una característica cause el abandono. Las recomendaciones deben interpretarse como hipótesis de intervención que requieren validación experimental y seguimiento. El modelo debe apoyar decisiones humanas y comerciales, no reemplazarlas.

11. Conclusiones

El proyecto permitió evolucionar desde un modelo baseline interpretable hacia una solución predictiva más potente y, posteriormente, complementar la predicción con una visión estructural de la cartera. La Regresión Logística aportó transparencia y una referencia metodológica. CatBoost mejoró de manera sustancial la detección de clientes que abandonan y fue seleccionado como modelo final por su equilibrio entre rendimiento y complejidad. K-Means identificó cuatro perfiles operativos que permiten diseñar estrategias diferenciadas, mientras que DBSCAN, PCA y t-SNE aportaron evidencia complementaria sobre densidad, variabilidad y heterogeneidad.

La integración de los resultados conduce a una recomendación concreta: utilizar CatBoost para priorizar a quién contactar y K-Means para orientar cómo intervenir. El Cluster 3 debe recibir atención intensiva por su tasa de churn, y el Cluster 2 debe ser abordado mediante acciones escalables por su volumen de abandonos. Los Clusters 0 y 1 requieren estrategias más eficientes y preventivas.

La implementación debería comenzar con un piloto controlado y medirse mediante retención incremental, costos y valor generado. La efectividad del sistema dependerá no solo de la calidad predictiva, sino también de la capacidad de integrar información económica, monitorear cambios, actualizar el modelo y validar las acciones con evidencia. El resultado final es un marco de retención más preciso, comprensible y segmentado.